

基於 ESP32 之輕量化多模態物聯網入侵偵測系統

(一) 摘要

本計畫目標聚焦於 IoT 裝置之安全監測，提出一個結合裝置 syslog + 網路入侵偵測系統 (NIDS) 及時異常偵測並防護的框架。系統將以 ESP32/ESP8266 來定期回傳關鍵狀態指標 (例如 uptime, RSSI, free_heap, status 等)，並透過對齊 syslog 格式與收集 (RFC5424)，同時部屬 NIDS 監控網路流量是否異常與警示。透過輕量模型 (microPython, XGBoost, RF, TinyML) 實現邊緣端的即時異常偵測。

本計畫預期成果包含：能重現的一套資料蒐集管線(syslog collector + NIDS sensor)，一份具正常和異常標註的資料集，以及可部屬於邊緣端的輕量模型，並以偵測率、誤報率、延遲、RAM/CPU 等指標作為驗證其可行性。

(二) 研究動機與研究問題

1. 研究動機

IoT 裝置目前常常面臨以下資安與工程限制：

- **環境多變化與可觀測性不足：**目前大部分研究都只聚焦在網路偵測 (NIDS) 或 syslog 上，然而實際情境的攻擊端常常會動原因、無限品質波動等)。單純依賴 syslog 端又難以掌握封包層的攻擊型態影響兩者，僅依賴 NIDS 容易缺乏裝置的內部狀態 (例如記憶體壓力、重啟原因、連線品質)。
- **可解釋性：**IoT 設備常常需要能快速定位警告的原因 (例如 RSSI 快速下降、重連次數突增、NIDS 警告增加)，且當前 XAI 的流行，採用可解釋性的輕量模型有助於實際的運行及後續調整。
- **資料整合挑戰：**裝置端 syslog 與 網路端 NIDS 在格式上與時間對齊上不一致，需要一個整理合併資料的管線與相關的時間對其機制。
- **資源受限：**許多 IoT 裝置僅具有有限的 RAM，導致難以長時間保留足夠資訊與大量封包或執行大型模型推論。

因此本計畫主張以 syslog 建立低成本「裝置可觀測性」，同時以 NIDS 提供「網路可觀測性」，再透過輕量模型融合判斷，使其能在有限資源下提升異常偵測的可靠性與可部署性。

2. 研究問題 (Research Questions)

本研究擬解決以下核心問題：

- **Q1：資源受限型設備 (ESP8266/ESP32) 的「低侵入式」日誌擷取與監控可行性為何？**現有研究多著重於 Gateway 等級之偵測，針對運算能力僅 240 MHz、記憶體 520 KB 的終端設備，探討在不影響 MCU 效能的前提下，如何

將內部狀態（如堆積記憶體 (Heap) 變化、異常重啟、中斷紀錄）轉化為能在最小成本下可供分析的日誌流。

- **Q2：syslog 與 NIDS 融合是否有效？** 現有物聯網資安研究多單獨使用網路入侵偵測 (NIDS) 和主機端系統日誌分析 (Syslog)。本研究想探討當 NIDS 偵測到異常時 (如 Deauth 攻擊)，是否能與內部 Syslog (如連線斷開的 Heap 波動) 產生關聯。藉由跨模態的關聯檢驗，預期能改善單一模型之誤報率 (False Postive Rate) 與漏報率 (False Negative Rate)。
- **Q3：資源受限型的模型如何產出？** 在記憶體與延遲的雙重限制下，現有模型難以直接於微處理器上運行。本研究參考 Lo 等人 [13] 之優化過程，探討如何透過模型編譯轉換技術而達成零依賴性 (Zero Dependency) 之 C 語言模型，並選擇合適的 baseline 進行後續的效能和部屬成本比較。
- **Q4：實體環境動態干擾下之「穩定性」如何？** Moharam 等人 [6] 指出在不同環境下 RSSI (訊號強度) 和 SNR 會根據部屬環境 (距離、障礙物) 而有所不同，本研究想探討如何建立一套動態基準值校正方法，使模型能在不重新訓練的前提下，能夠自適應不同環境下的雜訊而減少偵測偏差。

(三) 文獻回顧與探討

1. IoT 網路入侵偵測系統 (NIDS) 的技術演進與挑戰

早期的物聯網防禦機制多是使用「特徵偵測」(Signature-based Detection) 的偵測技術，藉由比對相關已知攻擊的特徵進行過濾。然而隨著網路攻擊技術的演進，這類的「靜態性防禦手段」在面對像是零日攻擊 (Zero-day Attack) 或變形惡意軟體 (Metamorphic Malware)，容易因缺乏對未知模式的識別能力顯得差強人意 [1,5]。所以，異常偵測 (Anomaly-based) 成為了主流的研究方向。Sethuraman 等人 [2] 也提出在 IEEE 802.11 網路的物理層攻擊 (例如 Evil Twin)，需要考慮封包以外的特徵。IoT 設備由於運算能力和記憶體等限制，頻繁更新龐大的特徵資料庫和計算複雜的模型十分困難，Nguyen 等人 [5] 提出的 Realguard 系統成功在 Gateway 層級上實現輕量 NIDS 模型。Mohara 等人 [6] 也進一步證實在 NodeMCU (ESP8266) 等微控制器上，利用 RSSI 與 SNR 等物理層面的數值來監測是可行的。然而我們意識到這類研究其實都存在一個共同的侷限性：「網路盲區」。一旦攻擊者成功滲透設備內，透過混淆或是加密技術，例如利用端到端加密 (End-to-End Encryption) 建立通訊，單純網路偵測器將無法解析內容而無法從中鑑別惡意行為特徵。

2. 系統日誌 (Syslog) 與主機行為監控的價值

為了彌補 NIDS 在面對加密流量與內網橫向移動 (Lateral Movement) 時的監測盲區，Host-based 的日誌分析被視為關鍵補充。像是 DeepLog [7] 成功利用長短期記憶網路 (LSTM) 捕捉系統日誌的執行序列，可以準確發現軟體執行的異常邏輯，但其實原始設計主要針對運算資源充足的雲端伺服器。在 IoT 設備可能將會面臨 RFC 3164 與 RFC 5424 格式差異和解析挑戰，且由於 IoT 儲存空間的限制會使長序列的 Syslog 的收集和訓練變得難以實現。這代表我們需要在現有的日誌分析系統模型取得在格式差異與輕量化間取得平衡。

比較面向	RFC3164	RFC5424
結構	簡單、可變	結構化
時間格式	MMM DD HH:MM:SS	ISO 8601(含 UTC)
字元編碼	僅 ASCII 碼	UTF-8
訊息長度限制	1024bytes	無預設限制
解析可靠性	低	高(格式嚴格)

3. 多模態融合 (Multi-modal Fusion) 的當前進展

隨著單一偵測維度有各自的限制與瓶頸，目前學術界正轉向多模態偵測方案結合「網路空間特徵」與「主機實體行為」。G. E. Mengmeng, R. Feng, and X. Yu [3] 與 Xu [4] 等人的研究顯示跨模態數據的互補性可以有效降低誤報率 (False Positive Rate)。

針對融合策略，學術界目前存在兩大爭議：

- 融合架構之爭 (Early v.s. Late Fusion): 早期融合 (Feature-level) 雖然能保留不同數據間的深度關聯，但由於輸入維度的增加會造成計算複雜度大幅提升。反之，Lin 等人 [14] 所採用的決策融合 (Decision-level)，其主要優勢在於能降低單一模型的計算成本。這是因為該架構將複雜的特徵提取任務分配到多個小型且獨立的子模型，僅針對個別子模型的初步結果進行結合，從而減少了輸入維度特徵造成的維數災難。雖然這樣較符合資源受限環境，卻損失了跨模態間的特徵關聯。
- 雲端與邊緣偵測之爭: Alrayes [1] 提出的 MAML (Model-Agnostic Meta-Learning) 框架，其核心理念是透過元學習 (Meta-Learning) 訓練出一組不錯的初始參數，使模型之後僅需少量的梯度更新或樣本資訊，使模型在不同環境下展現了強大的自適應性，但這類深度學習方案通常需要強大的 GPU 提供運算，這與僅具備 520 KB RAM，且缺乏專用 AI 硬體加速器的 IoT 微控制器 (ESP32) 形成鮮明對比。如何在不依靠高效能顯卡的情況下，將 MAML 的自適應能力輕量化部屬至邊緣端，是目前實務上的巨大挑戰。

綜合上述兩點，本計畫關注的核心論點：**高精度的多模態偵測是否能與極低資源的微控制器共存？**

4. 資源受限設備 (ESP32/8266) 之實作挑戰與模型優化

在微控制等級的設備 (ESP32/8266) 上部署入侵偵測模型，將面臨著極端的動態記憶體與運算資源瓶頸。雖然 Moharam 等人 [6] 證明了在 NodeMCU 上運行 LSTM/GRU 偵測 Wi-Fi 攻擊的可行性，但實務上模型的高權重占用容易引發資源競爭 (Resource Contention)，可能會導致設備難以同時處理 Syslog 收集和網路通訊工作。

針對此困境，Lo, Cheng 與 Kaliski [13] 的研究提出，目前主流的強大機器學習模型與函示庫(例如 scikit-learn) 因資源依賴性過高，無法直接移植部署於低階 AIoT 設備中。

此研究透過優化輕量級模型 (利用集成學習結合多個若學習器) 並配合特定推論引擎 (例如 emlearn 或 m2cgen)，能在維持可靠性的同時，還能降低推論延遲 [13]。

然而，目前的研究 [6, 13] 雖然解決了單一來源 (網路特徵或惡意軟體特徵) 的偵測問題，但在處理「多模態資料 (syslog 內部狀態 + NIDS 網路流量)」的時間對齊與格式標準化 (RFC5424) 上，目前仍不成熟，缺乏針對 ESP32 平台設計的統一代購。除此之外，如何在偵測異常時同時維持「模型可解釋性」也是一大挑戰。Siganos 等人 [10] 指出，若偵測系統僅能發出警報而無法解釋是因 RSSI 異常下降還是內部的 Heap Overflow 引起，將可能大幅降低工程實務上的修復效率。因此本計畫將透過可解釋性 AI 技術區分無線訊號 RSSI 之物理環境與內部系統資源 (如 Heap Overflow) 之攻擊，以提升定位故障的精確度。

5. 未解決之問題與本計畫之切入點

綜合上述文獻，目前 IoT 安全領域仍存在以下尚未完全解決，且本計畫預計突破之重點：

1. **資料對齊與標準化之技術瓶頸：**雖然現有研究如 DeepLog [7] 或機器學習方案已能有效處理資料格式差異的問題，但其應用場景多聚焦於具備高運算能力的伺服器環境。在 ESP 32 上，網路流量特徵 (毫秒級封包) 與系統日誌 (事件驅動之 RFC5424 格式) 在時間戳記對其上面臨挑戰。且由於微控制器內部缺乏高精度時脈源，還會因為時脈飄移 (Clock Drift) 倒置 NIDS 特徵與系統行為在關聯分析上產生誤差。對此本計畫將實作出一組基於優先權排成的非同步緩存機制，以確保日誌與流量資料能達成精準的時序對齊。
2. **邊緣模型效率：**現行學術界提出的多模態入侵偵測模型 (基於 CNN 或 Transformer 架構)，其模型權重儲存與推論運算常過程所需的記憶體 (RAM) 往往高達數十 MB 甚至數 GB。然而，實際的 IoT 邊緣裝置資源極度受限，以本計畫採用的 ESP32 為例，其可用 SRAM 僅約 520 KB，而 ESP8266 更僅有 50 KB 以下的可用空間。現有模型的資源需求遠遠超出了這些微控制器的物理極限，導致缺乏能真正落地於 ESP32/8266 等低成本晶片的高效輕量化模型。

本計畫將針對上述缺陷，提出一套可以結合標準化 syslog 收集與輕量多模態模型的偵測框架。

(四) 研究方法及步驟

本計畫目標是研發一套適用於資源受限設備 (ESP32/ESP8266) 之輕量化入侵偵測框架，透過整合網路封包 (NIDS) 與系統內部 (Syslog) 實現多模態異常偵測。研究方法將分成系統架構設計、資料採集與對齊、模型訓練與優化、以及實際驗證共四個階段。

1. 系統架構與設備

系統將採用邊緣計算架構，將偵測引擎直接部署於 ESP32 節點上使之能及時偵測。此選擇參考 Alrayes 等人 [1] 提出的自適應框架，強調在 IoT 終端進行及時響應以降低延遲。

- **硬體選用:** 參考 Moharam 等人 [6] 的實作經驗，也考量是目前 AIoT 市場普及的微控制器，選用 ESP32 或 ESP8266 作為主要感測器節點。尤其 ESP32 具備雙核處理能力，可以確保「網路封包監聽」與「系統日誌處理」任務並行處理。ESP8266 則資源極度受限 (約 32KB RAM)，可之後用於嘗試對模型的極限遷移做驗證。
- **攻擊主機與資料採集:** 使用 Kali Linux 作為安全性測試平台，利用其專業的滲透測試工具鏈 (例如 aireplay-ng, hping3 等)，針對 IoT 節點模擬真實世界的威脅行為。資料彙整則選用 Raspberry Pi 搭建的 rsyslog 服務 [5] 作為日誌收集器，以扮演工業常見的邊緣閘道器 (Edge Gateway)。
- **開發語言:** MicroPython 能快速建構資料採集與資料對齊等邏輯，可以兼顧開發彈性與執行效率。而核心推論模型將參考 [13] 建議，以 C 語言進行底層優化，以確保執行效率能維持及時偵測。

	ESP32	ESP8266
CPU	雙核(160~240MHZ)	單核(80~160MHZ)
RAM	520KB	< 50KB
FLASH	4MB	4MB

2. 資料採集開發

本研究之資料集分為「外部網路」與「內部系統」：

1. **NIDS 流量特徵:** 利用 ESP32 的混雜模式 (Promiscuous Mode) 進行 802.11 封包監聽。特徵選取將參考 Sethuraman [2] 與 Moharam [6] 的方法，預計聚焦於 RSSI, SNR 與序列號 (Sequence Number) 等物理層和連線層，以辨識 Deauth 或 SYN Flood 等導致的異常流量。
2. **Syslog 系統日誌:** 根據 RFC5424 標準，實作輕量化日誌發送程式。特徵建模參考 DeepLog [7]，將 Free_Heap 與 Task_Status 視為序列資料，以捕捉因攻擊引起的系統資源異常。
3. **資料集處理:** 本研究將參考 [14]，使用數種攻擊手段如 Mirai Botnet(DDoS)，亦或是 Kali Linux 上現成的工具(nmap, arpspoof...)進攻 ESP32 使其產生相應的 syslog 用於訓練模型。

3. 攻擊模擬與特徵工程

資料對齊是多模態分析的核心挑戰。由於 NIDS 流量是毫秒級的，而 Syslog 是事件驅動或秒級。本計畫將參考 Xu 等人 [4] 的建議，在 NIDS 流量端採用其提出的「固定封包與位元組擷取」策略，針對每個流的前 16 個封包並重組作為特徵圖。研究證實 6-30 個封包之區間已具備足夠之空間關聯特徵以供辨識，且能大幅降低 ESP32 的記憶體開銷。而在 Syslog 端，為了克服時間對齊的問題，本計畫強調「時間戳記的精準匹配」，如此才能建立網路層攻擊行為與系統層的內部波動間的因果關聯。

為了確保時間關聯性，預計進一步加入滑動視窗 (Sliding Window) 機制，將對齊精度設為 100 ms。這樣就能在 [4] 的特徵空間基礎上額外捕捉設備內部的資訊，以確保網路攻擊特徵能與微控制器的記憶體狀態有著精確的對應關係。


4. 模型優化與部屬

考量到 ESP32 的記憶體與算力，本研究捨棄運算成本較高的循環神經網路，並採較低成本模型(例如 XGBoost, Random Forest)作為核心偵測引擎，理由是這類樹狀模型在特徵不多的時候表現穩定。另外，為了進一步克服記憶體限制，利用知識蒸餾技術讓小模型能繼承大模型的特徵提取能力，和利用 m2cgen [13] 引擎將 Python 訓練之模型轉換為 C 語言的 Header 檔。如此可以移除大型函式庫依賴，符合 [13] 所強調的「零依賴性 (Zero-dependency)」部屬原則，確保模型可以嵌入於 ESP32 的 520KB RAM 中。

5. 評估表現與實驗設計

現成資料集多採用 CICIDS2017 [16] 等傳統 PC 端流量資料集，或較新的 CICIoT2023 [17] 等 IoT 設備流量集，但這類資料集多用於網路封包特徵，缺乏 ESP32 專屬的 Syslog (記憶體變化、訊號強度)。因此，本計畫使用 Edge-IIoTset [11] 定義攻擊類別(如 MQTT 惡意封包、非法存取等)，並自行製作具備 Syslog 特徵的專屬資料集驗證效能，包含偵測準確率、召回率、資源占用率、偵測延遲等。

6. 研究步驟時程



第 1–2 月：文獻深化研讀、採購實驗設備、搭建測試網路。

第 3–4 月：攻擊場景模擬、資料管線開發 (NIDS + RFC5424)。

第 5–6 月：多模態特徵提取、模型訓練比較、模型提取與優化。

第 7–8 月：硬體實測、效能評估、撰寫結案報告與成果發表。

(五) 預期結果

1. 實現 IoT 設備端的即時自動化阻斷

本系統的核心預期成果在於「即時反應」。當判定日誌行為具有高度威脅時，系統將不需等待雲端或中央閘道的指令，直接在 IoT 設備層或其直連的輕量級監控節點上觸發

防禦機制。預期能自動執行端口封鎖 (Port Blocking)、中斷連線或隔離受駭進程。這將證實防禦機制可從「事後分析」轉變為「當下攔截」。

2. 有效防止威脅橫向移動，保障 Router 安全

當 IoT 設備即時監測到攻擊發生時，可立即執行微斷層隔離(Micro-segmentation)，切斷該設備與 Router 間的連結。此外，亦可仿效 Hamarsheh [15] 等人，引入動態安全編排技術，將路由器作為 SDN 控制節點，在收到 IoT 設備斷開連接前的威脅預警時，發下新的安全策略給其他設備。路由器亦可將其自身的 syslog 傳輸到遠端伺服器以進行二次防護。

3. 輕量化部署與可視化監控

預期系統將證明在資源受限的環境下運行的可行性，並提供一個直觀的儀表板，將分析後的複雜日誌轉化為管理員易讀的資安警報。這不僅驗證在邊緣資安的應用潛力，也為未來建構更具韌性的物聯網生態系統提供了實證基礎。

(六) 需要指導教授指導內容

1. ML 模型的輕量化與邊緣部署策略

由於物聯網設備通常運算資源受限，如何將 ML 模型有效運行於邊緣節點或輕量級開道，是本專題的最大挑戰。我們需要教授指導如何選擇合適的開源模型（例如 XGBoost, Random Forest 等），以及在「模型量化」與「準確度」之間取得平衡，確保在不大幅犧牲偵測種類的前提下，達成即時監控的要求。

2. 真實攻擊場景的模擬與資料集建構

為了驗證系統能否有效保護 Router，我們需要構建具備信效度的測試環境。希望能請教授指導如何安全地在隔離沙箱中模擬真實的 IoT 攻擊行為（例如 Mirai 殭屍網路擴散、Telnet 暴力破解等），以收集高品質的訓練與測試日誌。同時，針對資安領域特有的「長尾分佈」攻擊樣本，如何進行資料增強或合成，亦需教授的指點。

3. 防禦機制觸發的門檻與系統整合

本專題的核心價值在於「阻斷」。當偵測到異常時，如何與底層網路架構進行連動，實施精準的阻斷而不影響正常服務，是實作上的難點。我們需要教授指導如何設定合理的分類閾值 (Classification Threshold) 門檻，以降低誤報率，避免因過度防禦而造成 IoT 設備可用性受損。

(七) 參考文獻

- [1] F.S. Alrayes, S. U. Amin, and N. Hakami, "An Adaptive Framework for Intrusion Detection in IoT Security Using MAML (Model-Agnostic Meta-Learning)," *Sensors*, vol. 25, no. 8, p. 2487, 2025, doi: 10.3390/s25082487.
- [2] S. C. Sethuraman, P. Vijayakumar, and S. Walia, "Intrusion detection system for detecting wireless attacks in IEEE 802.11 networks," *IET Networks*, vol. 7, no. 4, pp. 244–255, 2018, doi: 10.1049/iet-net.2018.5050.
- [3] G. E. Mengmeng, R. Feng, and X. Yu, "M-IDAS: Multi-modal Intrusion Detection and Analytic System," in *Proc. Int. Conf. Learn. Representations (ICLR)*, 2024. [Online]. Available: <https://openreview.net/forum?id=rTdbRWWdR5>
- [4] C. Xu, Y. Zhan, Z. Wang, and J. Yang, "Multimodal fusion based few-shot network intrusion detection system," *Scientific Reports*, vol. 15, no. 1, p. 21986, Jul. 2025, doi: 10.1038/s41598-025-05217-4.
- [5] X. H. Nguyen, X. D. Nguyen, H. H. Huynh, and K. H. Le, "Realguard: A lightweight network intrusion detection system for IoT gateways," *Sensors*, vol. 22, no. 2, p. 432, Jan. 2022, doi: 10.3390/s22020432.
- [6] M. H. Moharam, K. Ashraf, H. Alaa, M. Ahmed, and H. A. El-Hakim, "Real-time detection of Wi-Fi attacks using hybrid deep learning models on NodeMCU," *Sci. Rep.*, vol. 15, no. 1, p. 32544, Sep. 2025, doi: 10.1038/s41598-025-18947-2.
- [7] M. Du, F. Li, G. Zheng, and V. Srikumar, "DeepLog: Anomaly detection and diagnosis from system logs through deep learning," in *Proc. 2017 ACM SIGSAC Conf. Comput. Commun. Secur.*, 2017, pp. 1285–1298, doi: 10.1145/3133956.3134015.
- [8] R. Yasaei, Y. Moghaddas, and M. A. Al Faruque, "IoT-GRAF: IoT Graph Learning-Based Anomaly and Intrusion Detection Through Multi-Modal Data Fusion," in *Proc. 2024 Design, Automation & Test in Europe Conf. & Exhib. (DATE)*, 2024, pp. 1–6, doi: 10.23919/DATE58400.2024.10546572.
- [9] M. Antonini, M. Pincheira, M. Vecchio, and F. Antonelli, "An adaptable and unsupervised TinyML anomaly detection system for extreme industrial environments," *Sensors*, vol. 23, no. 4, p. 2344, Feb. 2023, doi: 10.3390/s23042344.
- [10] M. Siganos, P. Radoglou-Grammatikis, I. Kotsiuba, E. Markakis, I. Moscholios, S. Goudos, and P. Sarigiannidis, "Explainable ai-based intrusion detection in the internet of things," in *Proc. 18th Int. Conf. Availability, Reliability and Security (ARES)*, 2023, pp. 1–10, doi: 10.1145/3600160.3605162.
- [11] M. A. Ferrag, O. Friha, D. Hamouda, L. Maglaras, and H. Janicke, "Edge-IIoTset: A new comprehensive realistic cyber security dataset of IoT and IIoT applications for centralized and federated learning," *IEEE Access*, vol. 10, pp. 40281–40306, 2022, doi: 10.1109/ACCESS.2022.3165809.
- [12] G. Bovenzi, G. Aceto, D. Ciunzo, V. Persico, and A. Pescapé, "A hierarchical hybrid intrusion detection approach in IoT scenarios," in *2020 IEEE Global*

Communications Conference (GLOBECOM), Taipei, Taiwan, 2020, pp. 1-7, doi: 10.1109/GLOBECOM42002.2020.9348167

[13] F. Lo, S. M. Cheng, and R. Kaliski, "Optimization of Lightweight Malware Detection Models For AIoT Devices," in *Proc. 2023 IEEE 9th World Forum on Internet of Things (WF-IoT)*, 2023, pp. 1–6, doi: 10.1109/WF-IoT58464.2023.10539588.

[14] Y. -D. Lin, Z. Y. Wang, P. C. Lin, V. L. Nguyen, R. H. Hwang, and Y. C. Lai, "Multi-datasource machine learning in intrusion detection: Packet flows, system logs and host statistics," *Journal of Information Security and Applications*, vol. 68, p. 103248, Aug. 2022, doi: 10.1016/j.jisa.2022.103248.

[15] A. Hamarsheh, "An Adaptive Security Framework for Internet of Things Networks Leveraging SDN and Machine Learning," *Applied Sciences*, vol. 14, no. 11, p. 4530, May 2024, doi: 10.3390/app14114530.

[16] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization," in *Proc. 4th Int. Conf. Inf. Syst. Secur. Priv. (ICISSP)*, Portugal, Jan. 2018, pp. 108–116, doi: 10.5220/0006639801080116.

[17] E. C. P. Neto et al., "CICIoT2023: A real-time dataset and benchmark for large-scale attacks in IoT environment," *Sensors*, vol. 23, no. 13, p. 5941, Jun. 2023, doi: 10.3390/s23135941.